

Informe final de proyecto:

Replicación independiente del pipeline de Lopes et al. (2023)
sobre OpenNeuro ds004504 y comparación STFT vs
CWT-Morlet como etapa de descomposición tiempo-frecuencia

Sebastián Palacio Betancur

Universidad Nacional de Colombia – Sede Medellín
Facultad de Minas

Curso: Tópicos en Procesamiento Digital de Señales
Profesor: Freddy Bolaños

Junio de 2026

Resumen ejecutivo

Este trabajo replica de forma independiente el pipeline de Lopes et al. [1] (CNN sobre espectrograma de modulación de EEG con saliency-guided patches + SVM) sobre el dataset público OpenNeuro ds004504 [2] (65 sujetos: 36 AD + 29 HC), y extiende el análisis comparando **STFT** y **CWT-Morlet** como etapa de descomposición tiempo-frecuencia.

Las cifras principales se reportan como media $\pm$ SD entre 3 semillas de inicialización (LOSO-CV, 65 folds, anti-leakage estricto por fold en preproceso, saliency y selección de features):

Configuración	Acc	F1 macro	AUC
SVM saliency vainilla + STFT (paper-faithful)	0,764 $\pm$ 0,009	0,762 $\pm$ 0,011	0,856 $\pm$ 0,022
SVM saliency vainilla + CWT	0,677 $\pm$ 0,081	0,673 $\pm$ 0,094	0,778 $\pm$ 0,038
SVM saliency Grad-CAM + STFT	0,662 $\pm$ 0,031	0,643 $\pm$ 0,041	0,713 $\pm$ 0,020
SVM saliency Grad-CAM + CWT	0,703 $\pm$ 0,009	0,687 $\pm$ 0,026	0,800 $\pm$ 0,010
CNN end-to-end + STFT	0,656 $\pm$ 0,024	0,642 $\pm$ 0,020	0,695 $\pm$ 0,022
CNN end-to-end + CWT	0,626 $\pm$ 0,071	0,611 $\pm$ 0,070	0,590 $\pm$ 0,069

Cuadro 1: Resultados globales por configuración (3 seeds, LOSO-CV 65 folds).

Conclusiones clave (con matices estadísticos explícitos):

- La replicación independiente del pipeline funciona:** SVM con saliency vainilla y STFT alcanza Acc $0,764 \pm 0,009$, AUC $0,856 \pm 0,022$, en el rango del $0,71 \pm 0,02$ reportado por Lopes (T2: N vs AD). La comparación es orientativa, no equivalencia estricta (datasets y poblaciones distintas).
- La hipótesis original (CWT > STFT) no obtiene evidencia a favor, pero la dirección opuesta tampoco:** con saliency vainilla, AUC media de STFT supera la de CWT, pero DeLong por seed + combinación Stouffer/Fisher da $p \approx 0,061$ (NS), y tras BH-FDR sobre las 3 comparaciones principales *ninguna* sobrevive ($q \geq 0,10$). El “DeLong pooled $p = 0,014$ ” calculado sobre la mediana entre seeds (ensemble) sobreestima la separación.

3. **Confound DSP del eje de modulación (revisión externa)**: los ejes de modulación de STFT (Nyquist 1,56 Hz, 13 bins reales interpolados a 45) y CWT (Nyquist 100 Hz, ~ 180 bins subsampleados a 45) NO codifican el mismo contenido espectral. La comparación STFT vs CWT en este TFM está confundida con esta asimetría no controlada por diseño.
4. **El método de saliency afecta cualitativamente el ranking**: con Grad-CAM la tendencia se invierte (CWT > STFT, NS).
5. **Análisis exploratorio (post-hoc)**: STFT + vainilla concentra $\sim 89\%$ de la saliency en bandas α (61 %) + θ (28 %) y canales occipito-temporales (O1, O2, T5, T6), coherente con literatura clínica EEG-AD.

1. Introducción

1.1. Contexto clínico

La enfermedad de Alzheimer (EA) es la causa más común de demencia, con más de 55 millones de personas afectadas globalmente. El diagnóstico temprano es crítico para la intervención terapéutica. Las técnicas estándar de imagen (RM, PET) son costosas y poco accesibles. El EEG es no invasivo, portátil y económico, lo cual lo posiciona como herramienta promisorio para tamizaje a escala poblacional.

1.2. Espectrograma de modulación

El *espectrograma de modulación* del EEG captura periodicidades de segundo orden: cómo varía temporalmente la energía de cada componente espectral. Formalmente, dada una representación tiempo-frecuencia $X(t, f)$:

$$M(f, f_m) = \mathcal{F}_t \{ |X(t, f)|^2 \} \quad (1)$$

donde f es la frecuencia portadora y f_m la frecuencia de modulación. Trambaiolli [3], Fraga [4], Cassani [5] y Lopes [1] han demostrado consistentemente que esta representación captura biomarcadores discriminativos de EA.

1.3. Trabajo de referencia: Lopes et al. 2023

Lopes et al. [1] propusieron entrenar una CNN sobre el espectrograma de modulación y usar **mapas de saliencia** (vanilla gradient) para descubrir regiones discriminativas (“patches”). Sobre estos patches calculan potencia + ratios como features para un SVM final. Reportan accuracy $\sim 0,71$ en LOSO-test sobre $N = 39$ sujetos de un dataset privado.

1.4. Objetivos

1. **Validar de forma independiente** el pipeline de Lopes sobre el dataset público OpenNeuro ds004504.
2. **Comparar STFT vs CWT-Morlet** como etapa de descomposición tiempo-frecuencia.
3. **Cuantificar la varianza por seed** con multi-seed LOSO-CV (3 seeds).
4. **Analizar la interpretabilidad** de los patches descubiertos en términos de bandas canónicas y canales.

1.5. Pregunta de investigación

¿Produce la sustitución de la STFT por la CWT con wavelet de Morlet un espectrograma de modulación con mayor poder discriminativo para EA, y revela regiones de saliencia distintas a las reportadas por Lopes et al.?

2. Datos

OpenNeuro ds004504 [2]: 88 sujetos con EEG en reposo (ojos cerrados):

Grupo	N	Edad (media $\pm$ SD)	MMSE
A (Alzheimer, AD)	36	$66,4 \pm 7,9$	$17,8 \pm 4,5$
C (Healthy Control, HC)	29	$67,9 \pm 5,4$	$30,0 \pm 0,0$
F (Frontotemporal Dementia)	23	—	—

Cuadro 2: Composición del dataset ds004504.

Este TFM utiliza solo los grupos **A y C** (clasificación binaria AD vs HC, 65 sujetos). El grupo F (FTD) se excluyó del análisis principal.

Características técnicas:

- 19 canales 10-20 (Fp1, Fp2, F3, F4, C3, C4, P3, P4, O1, O2, F7, F8, T3, T4, T5, T6, Fz, Cz, Pz).
- Frecuencia de muestreo nativa: 500 Hz $\rightarrow$ resampleada a 200 Hz (alineación con Lopes).
- Duración registros: $\sim$ 10–13 min por sujeto.
- Licencia: CC0 1.0.

Análisis de confounders (AD vs HC):

Variable	AD	HC	Test	p
Edad	$66,4 \pm 7,9$	$67,9 \pm 5,4$	t -test	0,384 (NS)
MMSE	$17,8 \pm 4,5$	$30,0 \pm 0,0$	t -test	$< 0,001$ (esperado)
Género (F/M)	24/12	11/18	χ^2	0,039 (SIG)

Cuadro 3: Confounders demográficos. Existe sesgo significativo de género en el dataset, discutido en §5.4 y §5.5.

3. Pipeline implementado

3.1. Preproceso EEG

1. **Re-referencia:** promedio común (CAR).
2. **Filtro pasa-banda:** FIR fase cero, 0.5–45 Hz.
3. **Eliminación de artefactos:** ICA Infomax + ICLabel [8] (rechazo de componentes con $\text{prob} \geq 0,8$ para *eye blink*, *muscle artifact*, *heart beat*, *line noise*, *channel noise*). Desviación respecto al paper: Lopes usa wICA; ICLabel es una alternativa reproducible y estándar en MNE-Python.
4. **Resample** a 200 Hz.
5. `anonymize(daysback=10000)`.

3.2. Epoching

- Duración: 8 s, paso 1 s (overlap 7 s) $\rightarrow \sim 470$ epochs/sujeto.
- Descarte de los últimos 7 s para evitar leakage entre folds.

3.3. Espectrograma de modulación

- **STFT**: ventana Hann, $\text{nperseg}=128$, $\text{noverlap}=64$ a $f_s = 200$ Hz.
 - Resolución frecuencial portadora real: $\Delta f = f_s / \text{nperseg} = 1,5625$ Hz (no 1 Hz nominal).
 - Frecuencia de muestreo de la envolvente (eje temporal de la FFT de modulación): $dt = \text{noverlap} / f_s = 0,32$ s $\Rightarrow$ Nyquist de modulación = 1,5625 Hz.
- **CWT-Morlet** ($\text{cmor}1.5-1.0$, 32 escalas log en $[0,5, 45]$ Hz):
 - Frecuencia de muestreo de la envolvente: 200 Hz (CWT preserva f_s) $\Rightarrow$ Nyquist de modulación = 100 Hz, ~ 180 bins disponibles en $[0, 22,5]$ Hz.
- **Procesamiento común**: $|X|^2 \rightarrow$ FFT temporal $\rightarrow$ recorte ($[0,5, 45]$ Hz portadora, $[0, 22,5]$ Hz modulación) $\rightarrow$ resize bilinear a $45 \times 45 \rightarrow$ log-power.

Confound DSP del eje de modulación (revisión externa)

Las dos imágenes “ 45×45 ” finales **NO representan el mismo rango físico del eje de modulación**:

- STFT: 0 a **1,5625** Hz (interpolado de 13 bins reales a 45 vía bilinear).
- CWT: 0 a **22,5** Hz (subsampling de ~ 180 bins a 45).

La comparación cuantitativa STFT vs CWT bajo este pipeline NO es una comparación justa entre transformadas T-F: la STFT aquí captura solo modulaciones lentas ($\leq 1,56$ Hz, dinámica de envolvente α/θ), mientras que la CWT incluye modulaciones rápidas (hasta 22.5 Hz).

Mitigación correcta para trabajo futuro: decimar la envolvente CWT a la misma tasa de muestreo (3.125 Hz) antes de la FFT temporal, o computar la STFT con *hop* mucho más fino para igualar el Nyquist.

3.4. CNN — réplica de la arquitectura del paper

Capa	Detalle
Input	(19, 45, 45)
Conv2D #1	32 filtros, 3×3 , ReLU, padding 1
Dropout 2D	0,85
MaxPool	2×2
Conv2D #2	64 filtros, 3×3 , ReLU, padding 1
Dropout 2D	0,85
MaxPool	2×2
Flatten + FC#1	128 unidades, LeakyReLU(0,1), Dropout 0.85
FC#2	64 unidades, LeakyReLU(0,1), Dropout 0.85
FC#3 (output)	2 clases (AD/HC)

Cuadro 4: Arquitectura CNN replicada de Lopes et al. 2023.

- **Optimizer**: NAdam, $\text{lr}=10^{-4}$, $\text{weight_decay}=10^{-2}$ (L_2 del paper).

- **Batch size:** 128 (la GPU permite mayor que el batch 4 del paper; resultados estables).
- **Epochs:** 50 con *early stopping* (paciencia 10) sobre F1 macro de val.
- **AMP** (mixed precision) en GPU.
- **Class weights** balanceados.

3.5. Saliency por fold (anti-leakage estricto)

Para cada fold del LOSO:

1. Cargar el modelo entrenado en ese fold.
2. Para cada sujeto de train del fold (subset estratificado de 20):
 - **Grad-CAM** [6] sobre la última conv $\rightarrow$ mapa 45×45 por clase.
 - O bien **vainilla saliency** [7] — paper-faithful — gradiente $|\partial y / \partial x|$.
3. Promediar por clase $\rightarrow$ `saliency_AD`, `saliency_HC`.
4. `saliency_diff = saliency_AD - saliency_HC`.
5. Selección heurística de `threshold/K` por fold sobre `threshold  $\in \{80, 82, \dots, 96\}$` y `K  $\in \{3, 4, 5\}$` para KMeans $\rightarrow$ patches por fold.

Nota metodológica: la implementación efectiva (en `scripts/04_extract_saliency_features.py`) maximiza la separabilidad de la saliency map (max contraste AD vs HC sobre píxeles candidatos), NO una validación nested con SVM en val set. Se discute como limitación.

3.6. SVM con patches saliency-guided

1. Por epoch y canal: feature = potencia media en cada patch + ratios de potencia entre patches del mismo canal.
2. **Selección:** ANOVA F -value top-24 sobre train.
3. **MinMaxScaler** a $[-1, 1]$.
4. **SVM RBF** con $\gamma = 1/24$, $C = 1$, sin tuning (alineado con Lopes).

3.7. Validación

- **LOSO-CV** estricta con 65 folds.
- En cada fold, 1 sujeto adicional retenido para validación (early stopping).
- Z-score por canal con estadísticos SOLO de train.
- Saliency, patches y **SelectKBest por fold** (anti-leakage).
- 3 semillas (s0, s1, s2) por configuración $\rightarrow$ reportar media $\pm$ SD.

4. Resultados

4.1. CNN end-to-end (3 seeds)

Método	Acc	F1 macro	Sensibilidad	Especificidad	AUC
STFT	$0,656 \pm 0,024$	$0,642 \pm 0,020$	$0,741 \pm 0,029$	$0,552 \pm 0,034$	$0,695 \pm 0,022$
CWT	$0,626 \pm 0,071$	$0,611 \pm 0,070$	$0,602 \pm 0,060$	$0,655 \pm 0,087$	$0,590 \pm 0,069$

Cuadro 5: CNN end-to-end, multi-seed.

DeLong pooled (sobre mediana entre seeds): $\Delta\text{AUC}_{\text{STFT-CWT}} = +0,095$, $p = 0,252$ (NS).

La CNN sola opera apenas mejor que un *baseline trivial* (0.554 si siempre predice AD). Esto es coherente con su rol en el pipeline: la CNN no es el clasificador final, sino el *extractor* de regiones discriminativas vía saliency. Su accuracy modesta es esperada con dropout 0.85.

4.2. SVM con patches Grad-CAM (3 seeds)

Método	Acc	F1	AUC
STFT	$0,662 \pm 0,031$	$0,643 \pm 0,041$	$0,713 \pm 0,020$
CWT	$0,703 \pm 0,009$	$0,687 \pm 0,026$	$0,800 \pm 0,010$

Cuadro 6: SVM saliency Grad-CAM, multi-seed.

DeLong pooled: $\Delta\text{AUC}_{\text{CWT-STFT}} = +0,087$, $p = 0,195$ (NS). Con Grad-CAM, CWT tiende a ser mejor que STFT, pero la diferencia no alcanza significancia con 3 seeds.

4.3. SVM saliency vainilla (paper-faithful) — resultado principal

Método	Acc	F1	AUC
STFT	$0,764 \pm 0,009$	$0,762 \pm 0,011$	$0,856 \pm 0,022$
CWT	$0,677 \pm 0,081$	$0,673 \pm 0,094$	$0,778 \pm 0,038$

Cuadro 7: SVM saliency vainilla, multi-seed. Mejor configuración global.

DeLong “pooled” (sobre mediana entre seeds, ensemble): $\Delta\text{AUC} = +0,078$, $p = 0,014$.

Sub-óptimo metodológicamente

Este p -value se calcula sobre la mediana de scores entre 3 seeds (un ensemble), no sobre la distribución real por seed. La inferencia correcta se reporta en §4.3.3. El titular “ $p = 0,014$ ” debe leerse con esta caveat: corresponde al ensemble, no a la replicación de la diferencia.




Figura 1: Distribución de AUC por sujeto-test (LOSO) para SVM vainilla con STFT y CWT, agregada a través de 3 seeds. La superposición visible entre ambas distribuciones es coherente con la inferencia $p \approx 0,06$ (NS) reportada en §4.3.3.

4.3.1. Corrección por múltiples comparaciones (BH-FDR)

Las tres comparaciones principales (CNN, SVM Grad-CAM, SVM vainilla) corregidas por multiplicidad. Reportamos **dos versiones** de BH-FDR ($\alpha = 0,05$), ya que el p -value base depende de cómo se agreguen los seeds.

Versión A — DeLong “pooled” (sub-óptima, ensemble sobre mediana entre seeds):

Comparación	p (pooled)	BH-FDR q	Sig. tras corrección
SVM vainilla STFT vs CWT	0,014	0,042	✓ marginal
SVM Grad-CAM STFT vs CWT	0,195	0,293	×
CNN STFT vs CWT	0,252	0,252	×

Versión B — DeLong por seed + Stouffer combinado (recomendada):

Comparación	p (Stouffer combined)	BH-FDR q	Sig. tras corrección
SVM vainilla STFT vs CWT	0,061	0,102	×
SVM Grad-CAM STFT vs CWT	0,068	0,102	×
CNN STFT vs CWT	0,266	0,266	×

Conclusión actualizada: bajo la inferencia metodológicamente correcta (versión B), **nin-guna comparación sobrevive BH-FDR**. La aparente significancia marginal de la versión A ($q = 0,042$ en SVM vainilla) es artefacto del ensemble-de-mediana. La lectura definitiva del estudio es **ausencia de evidencia concluyente para superioridad de cualquier método T-F en este pipeline**.

4.3.2. Wilcoxon por seed individual (consistencia)

Wilcoxon pareado de scores por sujeto en cada seed individual (SVM vainilla, STFT vs CWT):

seed	Wilcoxon p
s_0	0,893 (NS)
s_1	0,025 (sig. sin corregir)
s_2	0,338 (NS)

Inconsistente entre semillas: solo en s_1 hay diferencia significativa, perdida tras Bonferroni intra-seed ($\alpha = 0,0167$).

4.3.3. DeLong por seed + combinación (lectura recomendada por revisión externa)

Repitiendo DeLong AUC pareado *dentro de cada seed por separado* (n=65 sujetos por test) y combinando con Stouffer/Fisher:

seed	AUC _{STFT}	AUC _{CWT}	Δ AUC	DeLong p
s_0	0,843	0,815	+0,028	0,660
s_1	0,844	0,739	+0,105	0,051
s_2	0,881	0,781	+0,101	0,072

Combinación de p -values entre seeds:

- Stouffer: $z = 1,55$, $p_{\text{combinado}} = \mathbf{0,061}$.
- Fisher: $\chi^2 = 12,03$, $p_{\text{combinado}} = \mathbf{0,061}$.

Esto es la inferencia metodológicamente correcta. Con DeLong por seed + combinación, el resultado es **NO significativo** ($p \approx 0,06$) al $\alpha = 0,05$, aunque marginal.

4.4. Comparación con el paper Lopes 2023

Métrica	Paper Lopes (T2: N vs AD, LOSO test)	Este TFM (SVM vainilla STFT, 3 seeds)
N sujetos	39 (20 N + 19 AD1)	65 (29 HC + 36 AD)
Accuracy	0,71 $\pm$ 0,02	0,764 $\pm$ 0,009
F1	0,61 $\pm$ 0,02	0,762 $\pm$ 0,011
AUC	no reportado	0,856 $\pm$ 0,022

Cuadro 8: Comparación con paper original. La comparación es orientativa; no equivalencia estricta (datasets, poblaciones y anti-leakage difieren).

El TFM obtiene cifras en el rango del paper o ligeramente superiores. Lo defendible es que **el pipeline funciona en el mismo orden de magnitud sobre datos públicos independientes**, que es el objetivo principal de un estudio de replicación.

4.5. Análisis de saliency: correlación 2D entre métodos

Comparación	Pearson r (3 seeds, media $\pm$ SD)
STFT vs CWT con Grad-CAM	-0,237 $\pm$ 0,119
STFT vs CWT con vainilla	-0,086 $\pm$ 0,076
Grad-CAM vs vainilla (STFT)	+0,114 $\pm$ 0,043
Grad-CAM vs vainilla (CWT)	-0,166 $\pm$ 0,106

Interpretación: los saliency maps STFT y CWT son **estadísticamente ortogonales** (Pearson $r \approx -0,09$ vainilla, $-0,24$ Grad-CAM; ningún $p < 0,05$ para $r \neq 0$). Hablar de “anti-correlación” sería sobreinterpretar el signo: las correlaciones son estadísticamente indistinguibles de cero. Lo mismo ocurre entre Grad-CAM y vainilla. Esto demuestra que “el biomarcador descubierto” depende fuertemente de la elección de pipeline.

4.6. Análisis por banda canónica (post-hoc, solo STFT)

Restricción del análisis a STFT

El eje de la portadora de la CWT está log-espaciado (**geospace**), por lo que la asignación píxel $\rightarrow$ banda canónica difiere de la de la STFT (**linspace**). El análisis aquí se restringe a STFT (eje lineal nativo); para CWT requeriría reescribir el mapeo en el script de post-experimentos.

Proporción de píxeles top-10 % saliency en cada banda canónica (media entre seeds):

Configuración	δ (0.5–4)	θ (4–8)	α (8–13)	β (13–30)	γ (30–45)
STFT vainilla	5.8 %	27,9 %	61,1 %	5.3 %	0.0 %
STFT Grad-CAM	0.0 %	0.0 %	0.0 %	0.7 %	99.3 %

Cuadro 9: Bandas canónicas en saliency (solo STFT, eje lineal). STFT + vainilla concentra $\sim 89\%$ en $\alpha + \theta$, coherente con biomarcadores clásicos EEG-AD.

4.7. Importancia por canal (post-hoc)

Agregando ANOVA F -score por canal sobre los features (potencia + ratios) del SVM vainilla STFT (mejor configuración):

Ranking	Canal	Score normalizado	Región
1	O2	$0,110 \pm 0,004$	Occipital derecho
2	T5	$0,110 \pm 0,006$	Temporal posterior izquierdo
3	O1	$0,103 \pm 0,005$	Occipital izquierdo
4	T6	$0,074 \pm 0,003$	Temporal posterior derecho
5	T3	$0,060 \pm 0,015$	Temporal medio izquierdo
		...	
19	C4	$0,014 \pm 0,004$	Central derecho

Cuadro 10: Importancia por canal del SVM vainilla STFT. Los canales más informativos son occipitales y temporales posteriores, coherentes con literatura clínica EEG-AD (atenuación α occipital, atrofia temporal medial).




Figura 2: Importancia por canal del SVM vainilla STFT (mejor configuración, AUC = 0,856).

4.8. Consistencia de patches entre folds (Jaccard)

Jaccard entre máscaras de patches de pares aleatorios de folds (200 pares por configuración):

Configuración	Jaccard medio $\pm$ SD
STFT Grad-CAM	0,050–0,063
STFT vainilla	0,036–0,051
CWT Grad-CAM	0,042–0,045
CWT vainilla	0,026–0,030

Los patches descubiertos son extremadamente inestables entre folds (Jaccard $\approx$ 0,03–0,06). Esto matiza la narrativa de “biomarcadores reproducibles”: cada fold descubre regiones distintas, aunque las métricas globales sean buenas.

4.9. Figura maestra




Figura 3: Resumen visual de AUC por configuración, agregando las 6 combinaciones (CNN/SVM vainilla/SVM Grad-CAM $\times$ STFT/CWT) con error bars entre seeds. Mejor configuración: SVM vainilla STFT (AUC = $0,856 \pm 0,022$).

5. Discusión

5.1. ¿CWT supera a STFT?

Respuesta matizada: no se encuentra evidencia a favor de CWT bajo esta configuración, pero tampoco se prueba formalmente la inferioridad intrínseca de CWT. Cuatro líneas de observación:

1. **DeLong AUC pooled** (SVM vainilla): STFT – CWT = +0,078, $p = 0,014$ (que se reduce a NS bajo la inferencia correcta por seed, §4.3.3).
2. **Wilcoxon por seed**: 0,893, 0,025, 0,338 — inconsistente entre semillas.
3. **Varianza entre seeds**: STFT vainilla tiene SD baja (acc $\pm 0,009$, AUC $\pm 0,022$), CWT vainilla muy alta (acc $\pm 0,081$, AUC $\pm 0,038$).
4. **Pipeline-dependent**: con Grad-CAM la tendencia se invierte (CWT > STFT en AUC, NS).

Por qué CWT puede estar penalizada en esta implementación, sin que necesariamente sea inferior:

- **Eje de frecuencia de modulación incomparable (confound DSP)**: Nyquist 1.56 Hz (STFT) vs 100 Hz (CWT). Tras el recorte a 22.5 Hz y resize a 45 bins, las dos imágenes representan rangos físicos distintos. Es el factor dominante de las diferencias observadas y debería corregirse antes de cualquier comparación seria.
- **Resize bilinear a 45×45** : iguala artificialmente las resoluciones nominales de salida.
- **CWT con cmor1.5-1.0 y 32 escalas log**: una elección entre muchas posibles, sin tuning específico.

- **Hiperparámetros del CNN** de Lopes optimizados para input STFT; CWT puede requerir tuning específico.
- **Las saliency maps de STFT y CWT están casi descorrelacionadas** ($r \approx -0,09$ vainilla, $-0,24$ Grad-CAM): indica **ortogonalidad/independencia**, no anti-correlación.

Lectura honesta: este trabajo NO sostiene una comparación equitativa entre transformadas T-F en sí mismas, sino entre **dos pipelines específicos** con ejes de modulación efectivamente distintos. Generalizar a “CWT-Morlet vs STFT en EEG-AD” requiere igualar los ejes primero.




Figura 4: Espectrogramas de modulación promedio (AD vs HC) bajo STFT y CWT. La presentación 45×45 oculta el desajuste en el rango del eje de modulación (Nyquist 1,56 Hz vs 100 Hz).

5.2. El método de saliency cambia el ranking

Hallazgo metodológico relevante: con Grad-CAM, CWT tiende a tener mejor AUC media; con vainilla (paper-faithful), STFT tiene mejor AUC media. Los saliency maps de los dos métodos no se parecen ($r \approx 0,11$ STFT, $-0,17$ CWT), lo que indica que descubren regiones distintas del espectrograma de modulación.

Esto implica que comparaciones del tipo “transformada X supera transformada Y ” son sensibles al método de saliency y al pipeline completo.




Figura 5: Comparación de saliency maps medios entre STFT y CWT bajo el método vainilla. Las distribuciones son cualitativamente distintas, coherente con Pearson $r \approx -0,09$.




Figura 6: Comparación cuantitativa SVM con saliency vainilla: STFT vs CWT por configuración.

5.3. Replicación del paper

Sobre ds004504, el SVM vainilla con STFT alcanza $\text{Acc} = 0,764 \pm 0,009$, $\text{AUC} = 0,856 \pm 0,022$, en el mismo orden de magnitud que el $0,71 \pm 0,02$ del paper en T2. La comparación numérica es **orientativa, no estricta**: datasets, poblaciones y detalles de anti-leakage difieren.




Figura 7: Curva ROC del SVM con saliency vainilla, agregada sobre todos los sujetos (LOSO).

5.4. Ensemble multi-seed y análisis estratificado por género

Ensemble: agregando las 3 semillas con votación por mediana (SVM vainilla STFT), la accuracy sube a 0,831 y AUC a 0,900.

Análisis estratificado por género (Fisher exact test sobre clasificación correcta):

Género	n	AD/HC	Aciertos	Acc	AUC
Mujer	35	24/11	27/35	0,771	0,852
Hombre	30	12/18	27/30	0,900	0,940
Diferencia	—	—	—	+0,129	+0,088
Fisher exact F vs M	—	—	OR $\approx 0,375$	p = 0,201	Cohen $h \approx 0,35$

Análisis de poder estadístico: con un tamaño de efecto Cohen $h \approx 0,35$ (moderado), detectar la diferencia observada al 80 % de poder y $\alpha = 0,05$ requeriría aproximadamente $N \approx 64$ sujetos por grupo (es decir, ~ 129 sujetos totales sumando F y M), según la fórmula con transformación arcoseno: $n_{\text{grupo}} = ((z_{1-\alpha/2} + z_{1-\beta})/h)^2 \approx 64$. El tamaño actual (35F + 30M) tiene poder $\sim 25\text{--}30\%$ para esa diferencia.

Lectura prudente: no se detectó diferencia significativa entre géneros, pero el poder estadístico es limitado — la diferencia absoluta de 12.9 puntos en accuracy es relevante en magnitud, y no podemos descartar un sesgo real del modelo. **Ausencia de evidencia no es evidencia de ausencia.**

5.5. Limitaciones

1. **Solo 3 seeds:** el multi-seed reporta varianza pero el número de réplicas es bajo para inferencias estadísticas fuertes. Idealmente ≥ 10 seeds.

2. **Grid search de patches heurístico, no nested CV**: selección por separabilidad de saliency map, no validación con SVM en val set.
3. **BH-FDR post-hoc**: la corrección se aplicó después de ver los resultados, no como pre-registro.
4. **Eje de modulación incomparable entre STFT y CWT** (confound DSP). Limitación más seria del trabajo. Solución: decimar la envolvente CWT a la tasa de muestreo de la envolvente STFT.
5. **Resize bilinear** oculta el desajuste anterior y puede penalizar artificialmente a CWT.
6. **CWT subexplorada**: solo $\text{cmor}1.5-1.0$ con 32 escalas log; sin cone-of-influence; sin tuning específico.
7. **Resolución STFT real $\neq$ nominal**: $\Delta f = 1,5625$ Hz, no 1 Hz exacto.
8. **DeLong sobre mediana entre seeds infla la separación**; inferencia correcta vía Stouffer/Fisher (§4.3.3).
9. **CNN sub-entrenada**: dropout 0.85 muy agresivo.
10. **Sin validación externa**: solo ds004504.
11. **Tareas binarias solamente**: el paper original tiene 5 tareas (T1–T5); este TFM replica solo T2.
12. **Poder estadístico modesto** para sub-análisis (género $N = 65$, potencia $\sim 25-30\%$ para $h \approx 0,35$).
13. **Saliency unstable fold-to-fold** (Jaccard $\approx 0,05$).
14. **Atribución de bandas canónicas restringida a STFT**: eje portador CWT (geospace) requiere mapeo distinto.
15. **N efectivo por autocorrelación de epochs**: el overlap 87.5% intra-sujeto NO afecta los tests reportados porque todas las inferencias finales son a nivel de sujeto.
16. **Análisis post-hoc** (bandas, importancia por canal, correlaciones, género) no estaban pre-registrados; deben verse como exploratorios.

5.6. Aporte propio

Más allá de la replicación, este TFM aporta:

1. **Evaluación multi-seed** del pipeline (el paper original no reporta varianza por seed). Aquí se cuantifica.
2. **Comparación rigurosa STFT vs CWT** con análisis estadístico explícito (DeLong por seed + Stouffer, Wilcoxon, BH-FDR) y reconocimiento de las limitaciones del diseño.
3. **Observación de pipeline-dependencia**: el método de saliency cambia el ranking entre STFT y CWT.
4. **Conexión exploratoria con literatura clínica**: STFT + vainilla concentra saliency en bandas $\alpha + \theta$ y canales occipito-temporales.
5. **Auditoría DSP + ML interna documentada** y validada por dos rondas de revisión externa.
6. **Reproducibilidad total**: repo público con `requirements-lock.txt`, seeds fijas, configs YAML, tests unitarios pasando.

6. Conclusiones

1. **El pipeline de Lopes et al. 2023 fue replicado funcionalmente** sobre el dataset público ds004504. SVM con saliency vainilla y STFT alcanza $\text{Acc} = 0,764 \pm 0,009$, $\text{AUC} = 0,856 \pm 0,022$ (3 seeds), en el orden de magnitud del $0,71 \pm 0,02$ reportado por Lopes en T2.
2. **La comparación STFT vs CWT no es concluyente y está confundida por DSP.** Tres caveats independientes:
 - *Inferencia estadística*: con saliency vainilla, AUC media de STFT ($0,856 \pm 0,022$) supera la de CWT ($0,778 \pm 0,038$), pero **DeLong por seed + combinación Stouffer/Fisher da $p \approx 0,061$ (NS)** y **tras BH-FDR ninguna sobrevive ($q \geq 0,10$)**.
 - *Confound DSP*: ejes de modulación no codifican el mismo contenido espectral.
 - *Sensibilidad a hiperparámetros*: resize 45×45 e hiperparámetros CWT-Morlet sin tuning exhaustivo.
3. **El ranking STFT vs CWT depende del método de saliency**: con Grad-CAM la tendencia se invierte ($\text{CWT} > \text{STFT}$, NS). Las saliency maps de STFT y CWT son **estadísticamente ortogonales** ($r \approx -0,09$ vainilla), sugiriendo complementariedad — un ensemble (late fusion) es hipótesis natural a futuro.
4. **Observaciones exploratorias (post-hoc)**: STFT + vainilla concentra saliency en bandas α (61 %) + θ (28 %) y canales occipito-temporales (O1, O2, T5, T6), coherente con biomarcadores clásicos de EA. Requiere validación en datasets independientes.
5. **Hallazgos metodológicos para la comunidad**:
 - El método de saliency afecta sustantivamente las conclusiones cuantitativas; reportar siempre el método específico.
 - Los patches descubiertos por saliency-guided ML son altamente inestables entre folds (Jaccard $\approx 0,05$): la narrativa de “biomarcadores reproducibles” debe matizarse.
 - Reportar varianza por seed es esencial.
 - El poder estadístico debe acompañar siempre las afirmaciones de “ausencia de efecto”.
6. **Recomendaciones para trabajos futuros**:
 - Unificar el eje de modulación entre STFT y CWT (downsample temporal post-CWT). **Pre-requisito para una comparación STFT vs CWT honesta.**
 - Ensemble STFT + CWT (late fusion) explotando ortogonalidad.
 - CWT tuning específico (cmor1-1, n_{scales} mayor, cone-of-influence).
 - Comparación T-F sin resize forzado.
 - Test externo en otro dataset EEG-AD.
 - Banco de filtros con bandas no uniformes.
 - Nested CV para grid search de patches.
 - Dataset balanceado por género o N mayor.
 - Más seeds (≥ 10) para inferencias por seed más sólidas.

7. Reproducibilidad

Repositorio: <https://github.com/spalaciobe/tps-alzheimer-modspec>

Para reproducir:

```
git clone https://github.com/spalaciobe/tps-alzheimer-modspec.git
cd tps-alzheimer-modspec
python -m venv .venv && source .venv/Scripts/activate
pip install -r requirements-lock.txt && pip install -e .
python scripts/00_download_dataset.py
bash scripts/run_remaining_v2.sh
```

Tiempos en RTX 3050 Laptop (4 GB):

- Preproceso 65 sujetos: ~ 35 min.
- Modspecs (STFT + CWT): ~ 90 min.
- LOSO CNN $\times 3$ seeds $\times 2$ métodos: ~ 14 h.
- Saliency $\times 12$ corridas: ~ 12 h.
- SVM $\times 12$ corridas: ~ 12 h.
- Post-análisis + figuras: ~ 30 min.

Total: ~ 48 h de cómputo continuo.

Stack: Python 3.13, PyTorch 2.6+cu124, MNE 1.12, scikit-learn 1.8.

Declaración de uso de IA

La estructura del pipeline, scripts de orquestación, debugging de leakage en LOSO-CV, refactor de optimización (SubjectBank, fp16-bank, GC entre folds), auditoría metodológica multi-dimensional y redacción de este informe fueron asistidos por **Claude Code** (Anthropic) [Opus 4.7, 2026]. Todo el código fue revisado, ejecutado y validado por el autor antes de cada commit.

Referencias

- [1] M. Lopes, R. Cassani, T. H. Falk. Using CNN saliency maps and EEG modulation spectra for improved and more interpretable machine learning-based Alzheimer’s disease diagnosis. *Computational Intelligence and Neuroscience*, vol. 2023, art. 3198066, 2023. DOI: [10.1155/2023/3198066](https://doi.org/10.1155/2023/3198066).
- [2] A. Miltiadous *et al.* A dataset of scalp EEG recordings of Alzheimer’s disease, frontotemporal dementia and healthy subjects from routine EEG. OpenNeuro **ds004504**, CC0 1.0, 2023.
- [3] L. R. Trambaiolli *et al.* EEG spectro-temporal modulation energy: A new feature for automated diagnosis of Alzheimer’s disease. *IEEE EMBC*, pp. 3828–3831, 2011.
- [4] F. J. Fraga *et al.* Characterizing Alzheimer’s disease severity via resting-awake EEG amplitude modulation analysis. *PLoS ONE*, vol. 8, no. 8, e72240, 2013.
- [5] R. Cassani, T. H. Falk. Alzheimer’s disease diagnosis and severity level detection based on EEG modulation spectral ‘patch’ features. *IEEE J. Biomed. Health Inform.*, vol. 24, no. 7, pp. 1982–1993, 2020.
- [6] R. R. Selvaraju *et al.* Grad-CAM: Visual explanations from deep networks via gradient-based localization. *ICCV*, 2017.

- [7] K. Simonyan, A. Vedaldi, A. Zisserman. Deep inside convolutional networks: Visualising image classification models and saliency maps. *ICLR Workshop*, 2014.
- [8] L. Pion-Tonachini, K. Kreutz-Delgado, S. Makeig. ICLabel: An automated electroencephalographic independent component classifier. *NeuroImage*, vol. 198, pp. 181–197, 2019.
- [9] A. Gramfort *et al.* MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, vol. 7, no. 267, 2013.
- [10] World Health Organization. Dementia fact sheet, 2023. <https://www.who.int/news-room/fact-sheets/detail/dementia>