

Informe final de proyecto:

Replicación independiente del pipeline de Lopes et al. (2023)
sobre OpenNeuro ds004504 y comparación STFT vs
CWT-Morlet como etapa de descomposición tiempo-frecuencia

Sebastián Palacio Betancur

Universidad Nacional de Colombia – Sede Medellín
Facultad de Minas

Curso: Tópicos en Procesamiento Digital de Señales
Profesor: Freddy Bolaños

Julio de 2026

Resumen ejecutivo

Este trabajo replica de forma independiente el pipeline de Lopes et al. [1] (CNN sobre espectrograma de modulación de EEG con saliency-guided patches + SVM) sobre el dataset público OpenNeuro ds004504 [2] (65 sujetos: 36 AD + 29 HC), y extiende el análisis comparando **STFT** y **CWT-Morlet** como etapa de descomposición tiempo-frecuencia.

Las cifras principales se reportan como media $\pm$ SD entre 3 semillas de inicialización (LOSO-CV, 65 folds, anti-leakage estricto por fold en preproceso, saliency y selección de features). Para separar el efecto de la **transformada** del de un **artefacto de DSP** en el eje de modulación (§3.3), se evalúan **tres** representaciones tiempo-frecuencia: STFT, CWT-Morlet nativa, y **CWT-fair** (CWT con la envolvente decimada para igualar el eje de modulación de la STFT — misma resolución de modulación, distinta resolución de portadora).

Clasificador	T-F	Acc	F1 macro	AUC
SVM vainilla (paper-faithful)	STFT	0,764 $\pm$ 0,009	0,760 $\pm$ 0,008	0,856 $\pm$ 0,022
SVM vainilla	CWT nativa	0,677 $\pm$ 0,081	0,670 $\pm$ 0,085	0,778 $\pm$ 0,038
SVM vainilla	CWT-fair	0,754 $\pm$ 0,046	0,750 $\pm$ 0,046	0,828 $\pm$ 0,031
SVM Grad-CAM	STFT	0,662 $\pm$ 0,031	0,643 $\pm$ 0,033	0,713 $\pm$ 0,020
SVM Grad-CAM	CWT nativa	0,703 $\pm$ 0,009	0,697 $\pm$ 0,012	0,800 $\pm$ 0,010
SVM Grad-CAM	CWT-fair	0,682 $\pm$ 0,054	0,673 $\pm$ 0,050	0,769 $\pm$ 0,045
CNN end-to-end	STFT	0,656 $\pm$ 0,024	0,647 $\pm$ 0,024	0,695 $\pm$ 0,022
CNN end-to-end	CWT nativa	0,626 $\pm$ 0,071	0,625 $\pm$ 0,071	0,590 $\pm$ 0,069
CNN end-to-end	CWT-fair	0,656 $\pm$ 0,062	0,655 $\pm$ 0,061	0,667 $\pm$ 0,067

Cuadro 1: Resultados globales por configuración (3 seeds, LOSO-CV 65 folds).

Conclusiones clave (con matices estadísticos explícitos):

1. **La replicación independiente del pipeline funciona:** SVM con saliency vainilla y STFT alcanza **Acc** 0,764 $\pm$ 0,009 (comparable con el Acc 0,71 $\pm$ 0,02 de Lopes en T2: N vs AD; el paper no reporta AUC), con **AUC** 0,856 $\pm$ 0,022. La comparación es orientativa, no equivalencia estricta.

2. **Las diferencias aparentes STFT vs CWT eran en gran parte un artefacto de DSP, no de la transformada.** El eje de modulación de la STFT (Nyquist 1.56 Hz) y el de la CWT nativa (Nyquist 100 Hz) NO codifican el mismo contenido antes del resize a 45×45 . Al igualarlos (CWT-fair), la brecha con STFT se reduce sustancialmente en ambos métodos de saliency, aunque en distinta magnitud: con vainilla la CWT pasa de $-0,078$ AUC a **$-0,028$** ($\sim 64\%$); con Grad-CAM de $+0,087$ a **$+0,056$** ($\sim 36\%$, donde el eje explica solo parte de la brecha). En ambos casos igualar el eje **mueve la CWT hacia la STFT**.
3. **Con el eje de modulación igualado, STFT y CWT son estadísticamente indistinguibles.** DeLong por seed + Stouffer: STFT vs CWT-fair $p = 0,318$ (vainilla), $0,587$ (Grad-CAM); CWT nativa vs CWT-fair $p = 0,283, 0,527$. Ninguna comparación es significativa. **No encontramos evidencia de que la elección STFT vs CWT-Morlet cambie el desempeño una vez controlado el eje** (potencia limitada, 3 seeds); ni la hipótesis original (CWT > STFT) ni la inversa obtienen evidencia.
4. **El método de saliency afecta el ranking aparente entre STFT y CWT nativa** (Grad-CAM: CWT mejor; vainilla: STFT mejor), pero esa sensibilidad **se atenúa con CWT-fair**: buena parte del “cambio de ranking” también era el artefacto DSP.
5. **Análisis exploratorio (post-hoc):** STFT + vainilla concentra $\sim 89\%$ de la saliency en bandas α (61%) + θ (28%) y canales occipito-temporales (O1, O2, T5, T6), coherente con literatura clínica EEG-AD.

1. Introducción

1.1. Contexto clínico

La enfermedad de Alzheimer (EA) es la causa más común de demencia, con más de 55 millones de personas afectadas globalmente. El diagnóstico temprano es crítico para la intervención terapéutica. Las técnicas estándar de imagen (RM, PET) son costosas y poco accesibles. El EEG es no invasivo, portátil y económico, lo cual lo posiciona como herramienta promisorio para tamizaje a escala poblacional.

1.2. Espectrograma de modulación

El *espectrograma de modulación* del EEG captura periodicidades de segundo orden: cómo varía temporalmente la energía de cada componente espectral. Formalmente, dada una representación tiempo-frecuencia $X(t, f)$:

$$M(f, f_m) = \mathcal{F}_t \{ |X(t, f)|^2 \} \quad (1)$$

donde f es la frecuencia portadora y f_m la frecuencia de modulación. Trambaiolli [3], Fraga [4], Cassani [5] y Lopes [1] han demostrado consistentemente que esta representación captura biomarcadores discriminativos de EA.

1.3. Trabajo de referencia: Lopes et al. 2023

Lopes et al. [1] propusieron entrenar una CNN sobre el espectrograma de modulación y usar **mapas de saliencia** (vanilla gradient) para descubrir regiones discriminativas (“patches”). Sobre estos patches calculan potencia + ratios como features para un SVM final. Reportan accuracy $\sim 0,71$ en LOSO-test sobre $N = 39$ sujetos de un dataset privado.

1.4. Objetivos

1. **Validar de forma independiente** el pipeline de Lopes sobre el dataset público OpenNeuro ds004504.
2. **Comparar STFT vs CWT-Morlet** como etapa de descomposición tiempo-frecuencia.
3. **Cuantificar la varianza por seed** con multi-seed LOSO-CV (3 seeds).
4. **Analizar la interpretabilidad** de los patches descubiertos en términos de bandas canónicas y canales.

1.5. Pregunta de investigación

¿Produce la sustitución de la STFT por la CWT con wavelet de Morlet un espectrograma de modulación con mayor poder discriminativo para EA, y revela regiones de saliencia distintas a las reportadas por Lopes et al.?

2. Datos

OpenNeuro ds004504 [2]: 88 sujetos con EEG en reposo (ojos cerrados):

Grupo	N	Edad (media $\pm$ SD)	MMSE
A (Alzheimer, AD)	36	$66,4 \pm 7,9$	$17,8 \pm 4,5$
C (Healthy Control, HC)	29	$67,9 \pm 5,4$	$30,0 \pm 0,0$
F (Frontotemporal Dementia)	23	—	—

Cuadro 2: Composición del dataset ds004504.

Este TFM utiliza solo los grupos **A** y **C** (clasificación binaria AD vs HC, 65 sujetos). El grupo F (FTD) se excluyó del análisis principal.

Características técnicas:

- 19 canales 10-20 (Fp1, Fp2, F3, F4, C3, C4, P3, P4, O1, O2, F7, F8, T3, T4, T5, T6, Fz, Cz, Pz).
- Frecuencia de muestreo nativa: 500 Hz $\rightarrow$ resampleada a 200 Hz (alineación con Lopes).
- Duración registros: $\sim$ 10–13 min por sujeto.
- Licencia: CC0 1.0.

Análisis de confounders (AD vs HC):

Variable	AD	HC	Test	p
Edad	$66,4 \pm 7,9$	$67,9 \pm 5,4$	t -test	0,384 (NS)
MMSE	$17,8 \pm 4,5$	$30,0 \pm 0,0$	t -test	$< 0,001$ (esperado)
Género (F/M)	24/12	11/18	χ^2	0,039 (SIG)

Cuadro 3: Confounders demográficos. Existe sesgo significativo de género en el dataset, discutido en §5.4 y §5.5.

3. Pipeline implementado

3.1. Preproceso EEG

1. **Re-referencia:** promedio común (CAR).
2. **Filtro pasa-banda:** FIR fase cero, 0.5–45 Hz.
3. **Eliminación de artefactos:** ICA Infomax + ICLabel [8] (rechazo de componentes con $\text{prob} \geq 0,8$ para *eye blink*, *muscle artifact*, *heart beat*, *line noise*, *channel noise*). Desviación respecto al paper: Lopes usa wICA; ICLabel es una alternativa reproducible y estándar en MNE-Python.
4. **Resample** a 200 Hz.
5. `anonymize(daysback=10000)`.

3.2. Epoching

- Duración: 8 s, paso 1 s (overlap 7 s) $\rightarrow \sim 470$ epochs/sujeto.
- Descarte de los últimos 7 s para evitar leakage entre folds.

3.3. Espectrograma de modulación

- **STFT:** ventana Hann, `nperseg=128`, `noverlap=64` a $f_s = 200$ Hz.
 - Resolución frecuencial portadora real: $\Delta f = f_s / \text{nperseg} = 1,5625$ Hz (no 1 Hz nominal).
 - Frecuencia de muestreo de la envolvente (eje temporal de la FFT de modulación): $dt = \text{noverlap} / f_s = 0,32$ s $\Rightarrow$ Nyquist de modulación = 1,5625 Hz.
- **CWT-Morlet nativa** (`cmor1.5-1.0`, 32 escalas log en [0,5, 45] Hz):
 - Frecuencia de muestreo de la envolvente: 200 Hz (CWT preserva f_s) $\Rightarrow$ Nyquist de modulación = 100 Hz, ~ 180 bins disponibles en [0, 22,5] Hz.
- **CWT-fair** (misma CWT-Morlet, misma portadora): la envolvente de potencia se **decima a 3.125 Hz** (anti-alias poly-phase FIR) *antes* de la FFT temporal, igualando el Nyquist de modulación de la STFT (1.5625 Hz, ~ 13 bins reales). Solo cambia el eje de modulación; la descomposición de portadora (wavelet, 32 escalas) es idéntica a la CWT nativa.
- **Procesamiento común:** $|X|^2 \rightarrow$ FFT temporal $\rightarrow$ recorte ([0,5, 45] Hz portadora, [0, 22,5] Hz modulación) $\rightarrow$ resize bilinear a $45 \times 45 \rightarrow$ log-power.

Asimetría de DSP en el eje de modulación — y cómo se controla

Las imágenes “ 45×45 ” de STFT y CWT nativa **NO** representan el mismo rango físico del eje de modulación:

- STFT: 0 a **1,5625** Hz (interpolado de 13 bins reales a 45 vía bilinear).
- CWT nativa: 0 a **22,5** Hz (subsampling de ~ 180 bins a 45).

Por tanto, una comparación STFT vs CWT nativa mezcla dos efectos: la **transformada** (resolución de portadora) y la **resolución del eje de modulación**. Para separarlos se introduce **CWT-fair**, que mantiene la transformada CWT pero iguala el eje de modulación al de la STFT. Así:

- **STFT vs CWT-fair** aísla el efecto de la transformada a igualdad de eje (comparación justa).

- **CWT nativa vs CWT-fair** cuantifica el artefacto de DSP.

Resultado (§4.3): ambas comparaciones son **no significativas** — la asimetría de DSP explica la mayor parte de las diferencias aparentes STFT↔CWT.

Nota: CWT-fair “igualada hacia abajo” (descarta las modulaciones rápidas de la CWT). Es fisiológicamente defendible (la AM diagnóstica en EA es lenta, < 2 Hz; Fraga 2013), pero es una de dos definiciones de “justo”; la alternativa (subir la STFT con hop fino) se deja como trabajo futuro (§5.5).

3.4. CNN — réplica de la arquitectura del paper

Capa	Detalle
Input	(19, 45, 45)
Conv2D #1	32 filtros, 3×3 , ReLU, padding 1
Dropout 2D	0,85
MaxPool	2×2
Conv2D #2	64 filtros, 3×3 , ReLU, padding 1
Dropout 2D	0,85
MaxPool	2×2
Flatten + FC#1	128 unidades, LeakyReLU(0,1), Dropout 0.85
FC#2	64 unidades, LeakyReLU(0,1), Dropout 0.85
FC#3 (output)	2 clases (AD/HC)

Cuadro 4: Arquitectura CNN replicada de Lopes et al. 2023.

- **Optimizer:** NAdam, $lr=10^{-4}$, $weight_decay=10^{-2}$ (L_2 del paper).
- **Batch size:** 128 (la GPU permite mayor que el batch 4 del paper; resultados estables).
- **Epochs:** 50 con *early stopping* (paciencia 10) sobre F1 macro de val.
- **AMP** (mixed precision) en GPU.
- **Class weights** balanceados.

3.5. Saliency por fold (anti-leakage estricto)

Para cada fold del LOSO:

1. Cargar el modelo entrenado en ese fold.
2. Para cada sujeto de train del fold (subset estratificado de 20):
 - **Grad-CAM** [6] sobre la última conv $\rightarrow$ mapa 45×45 por clase.
 - O bien **vainilla saliency** [7] — paper-faithful — gradiente $|\partial y / \partial x|$.
3. Promediar por clase $\rightarrow$ saliency_AD, saliency_HC.
4. $saliency_diff = saliency_AD - saliency_HC$.
5. Selección heurística de threshold/ K por fold sobre $threshold \in \{80, 82, \dots, 96\} \%$ y $K \in \{3, 4, 5\}$ para KMeans $\rightarrow$ patches por fold.

Nota metodológica: la implementación efectiva (en `scripts/04_extract_saliency_features.py`) maximiza la separabilidad de la saliency map (max contraste AD vs HC sobre píxeles candidatos), NO una validación nested con SVM en val set. Se discute como limitación.

3.6. SVM con patches saliency-guided

1. Por epoch y canal: feature = potencia media en cada patch + ratios de potencia entre patches del mismo canal.
2. **Selección**: ANOVA F -value top-24 sobre train.
3. **MinMaxScaler** a $[-1, 1]$.
4. **SVM RBF** con $\gamma = 1/24$, $C = 1$, sin tuning (alineado con Lopes).

3.7. Validación

- **LOSO-CV** estricta con 65 folds.
- En cada fold, 1 sujeto adicional retenido para validación (early stopping).
- Z-score por canal con estadísticos SOLO de train.
- Saliency, patches y **SelectKBest por fold** (anti-leakage).
- 3 semillas (s0, s1, s2) por configuración $\rightarrow$ reportar media $\pm$ SD.

4. Resultados

Cada tabla compara las **tres** representaciones T-F: STFT, CWT nativa y CWT-fair (CWT con el eje de modulación igualado a la STFT, §3.3).

4.1. CNN end-to-end (3 seeds)

T-F	Acc	F1 macro	AUC
STFT	$0,656 \pm 0,024$	$0,647 \pm 0,024$	$0,695 \pm 0,022$
CWT nativa	$0,626 \pm 0,071$	$0,625 \pm 0,071$	$0,590 \pm 0,069$
CWT-fair	$0,656 \pm 0,062$	$0,655 \pm 0,061$	$0,667 \pm 0,067$

Cuadro 5: CNN end-to-end, multi-seed.

Igualar el eje de modulación **recupera la mayor parte del déficit de la CWT** también en la CNN: AUC pasa de 0.590 (nativa) a 0.667 (fair), acercándose a STFT (0.695). La CNN sola opera cerca del baseline trivial (0.554), coherente con su rol de extractor (no clasificador final) y su dropout 0.85.

4.2. SVM con patches Grad-CAM (3 seeds)

T-F	Acc	F1	AUC
STFT	$0,662 \pm 0,031$	$0,643 \pm 0,033$	$0,713 \pm 0,020$
CWT nativa	$0,703 \pm 0,009$	$0,697 \pm 0,012$	$0,800 \pm 0,010$
CWT-fair	$0,682 \pm 0,054$	$0,673 \pm 0,050$	$0,769 \pm 0,045$

Cuadro 6: SVM saliency Grad-CAM, multi-seed.

Con Grad-CAM, la CWT **nativa** parecía la mejor (0.800). Pero al igualar el eje de modulación, CWT-fair baja a 0.769 — **acercándose a STFT**. La ventaja aparente de la CWT nativa

era en parte el eje de modulación más rico, no la transformada. DeLong por seed (Stouffer): STFT vs CWT-fair $p = 0,587$; CWT nativa vs CWT-fair $p = 0,527$ — ambas NS.

4.3. SVM saliency vainilla (paper-faithful) — resultado principal

T-F	Acc	F1	AUC
STFT	$0,764 \pm 0,009$	$0,760 \pm 0,008$	$0,856 \pm 0,022$
CWT nativa	$0,677 \pm 0,081$	$0,670 \pm 0,085$	$0,778 \pm 0,038$
CWT-fair	$0,754 \pm 0,046$	$0,750 \pm 0,046$	$0,828 \pm 0,031$

Cuadro 7: SVM saliency vainilla, multi-seed. Mejor AUC individual: STFT.

4.3.1. Comparación justa: DeLong por seed + combinación

DeLong AUC pareado *dentro de cada seed* ($n=65$ por test LOSO), combinado entre seeds con Stouffer/Fisher. Se reportan tres comparaciones:

Comparación	Δ AUC por seed	Stouffer p	Lectura
STFT vs CWT nativa (confundida)	$+0,028, +0,105, +0,101$	0,061	marginal — mezcla transformada + eje
STFT vs CWT-fair (justa)	$-0,021, +0,036, +0,069$	0,318	NS — sin diferencia a igualdad de eje
CWT nativa vs CWT-fair (efecto eje)	$-0,049, -0,069, -0,032$	0,283	NS — el eje explica el grueso

Interpretación: la ventaja marginal de STFT sobre la CWT nativa ($p = 0,061$) **se disuelve** a $p = 0,318$ **cuando se iguala el eje de modulación** (STFT vs CWT-fair). Ese $p \approx 0,06$ estaba impulsado por el artefacto de DSP, no por la transformada. La CWT-fair recupera la brecha ($0,778 \rightarrow 0,828$ AUC, $-0,078 \rightarrow -0,028$ vs STFT). **A igualdad de eje de modulación, STFT y CWT-Morlet son estadísticamente indistinguibles.**




Figura 1: Distribución de AUC por sujeto-test (LOSO) para SVM vainilla, agregada a través de 3 seeds.

4.3.2. Corrección por múltiples comparaciones (BH-FDR)

Corrección Benjamini-Hochberg ($\alpha = 0,05$) sobre los p -values combinados (Stouffer) de las comparaciones **justas** STFT vs CWT-fair (las que aíslan la transformada):

Comparación justa (STFT vs CWT-fair)	p (Stouffer)	BH-FDR q	Sig.
SVM vainilla	0,318	0,679	×
SVM Grad-CAM	0,587	0,679	×
CNN	0,679	0,679	×

Familia de $m = 3$ comparaciones (CNN, SVM Grad-CAM, SVM vainilla). **Ninguna comparación justa se acerca a la significancia** ($q \approx 0,68$ en las tres). Para contexto, la comparación *confundida* STFT vs CWT nativa ($p = 0,061$ vainilla, $0,068$ Grad-CAM) era marginal y tampoco significativa tras corrección; las justas quedan mucho más lejos. **A igualdad de eje de modulación, no hay evidencia de superioridad de ninguna transformada T-F en este pipeline.**

4.3.3. Wilcoxon por seed individual (consistencia)

Wilcoxon pareado de scores por sujeto en cada seed (SVM vainilla, STFT vs CWT nativa) corrobora la falta de un efecto consistente incluso en la comparación confundida:

seed	Wilcoxon p
s_0	0,893 (NS)
s_1	0,025 (sig. sin corregir)
s_2	0,338 (NS)

Solo en s_1 hay diferencia significativa, perdida tras Bonferroni intra-seed ($\alpha = 0,0167$). La señal no se replica entre semillas.

4.4. Comparación con el paper Lopes 2023

Métrica	Paper Lopes (T2: N vs AD, LOSO test)	Este TFM (SVM vainilla STFT, 3 seeds)
N sujetos	39 (20 N + 19 AD1)	65 (29 HC + 36 AD)
Accuracy	$0,71 \pm 0,02$	$0,764 \pm 0,009$
F1	$0,61 \pm 0,02$	$0,760 \pm 0,008$
AUC	no reportado	$0,856 \pm 0,022$

Cuadro 8: Comparación con paper original. La comparación es orientativa; no equivalencia estricta (datasets, poblaciones y anti-leakage difieren).

El TFM obtiene cifras en el rango del paper o ligeramente superiores. Lo defendible es que **el pipeline funciona en el mismo orden de magnitud sobre datos públicos independientes**, que es el objetivo principal de un estudio de replicación.

4.5. Análisis de saliency: correlación 2D entre métodos

Comparación	Pearson r (3 seeds, media $\pm$ SD)
STFT vs CWT con Grad-CAM	$-0,237 \pm 0,119$
STFT vs CWT con vainilla	$-0,086 \pm 0,076$
Grad-CAM vs vainilla (STFT)	$+0,114 \pm 0,043$
Grad-CAM vs vainilla (CWT)	$-0,166 \pm 0,106$

Interpretación: los saliency maps STFT y CWT están **débilmente correlacionados, cerca de cero** (Pearson $r \approx -0,09$ vainilla, $-0,24$ Grad-CAM, promedio de 3 seeds). Con solo 3 seeds no se puede afirmar *independencia* estadística; lo defendible es que no hay una correlación fuerte, y hablar de “anti-correlación” sobreinterpretaría el signo. Lo mismo ocurre entre Grad-CAM y vainilla. Esto sugiere que “el biomarcador descubierto” depende de la elección de pipeline.

4.6. Análisis por banda canónica (post-hoc, solo STFT)

Restricción del análisis a STFT

El eje de la portadora de la CWT está log-espaciado (**geospace**), por lo que la asignación píxel $\rightarrow$ banda canónica difiere de la de la STFT (**linspace**). El análisis aquí se restringe a STFT (eje lineal nativo); para CWT requeriría reescribir el mapeo en el script de post-experimentos.

Proporción de píxeles top-10 % saliency en cada banda canónica (media entre seeds):

Configuración	δ (0.5–4)	θ (4–8)	α (8–13)	β (13–30)	γ (30–45)
STFT vainilla	5.8 %	27,9 %	61,1 %	5.3 %	0.0 %
STFT Grad-CAM	0.0 %	0.0 %	0.0 %	0.7 %	99.3 %

Cuadro 9: Bandas canónicas en saliency (solo STFT, eje lineal). STFT + vainilla concentra $\sim 89\%$ en $\alpha + \theta$, coherente con biomarcadores clásicos EEG-AD.

4.7. Importancia por canal (post-hoc)

Agregando ANOVA F -score por canal sobre los features (potencia + ratios) del SVM vainilla STFT (mejor configuración):

Ranking	Canal	Score normalizado	Región
1	O2	$0,110 \pm 0,004$	Occipital derecho
2	T5	$0,110 \pm 0,006$	Temporal posterior izquierdo
3	O1	$0,103 \pm 0,005$	Occipital izquierdo
4	T6	$0,074 \pm 0,003$	Temporal posterior derecho
5	T3	$0,060 \pm 0,015$	Temporal medio izquierdo
		...	
19	C4	$0,014 \pm 0,004$	Central derecho

Cuadro 10: Importancia por canal del SVM vainilla STFT. Los canales más informativos son occipitales y temporales posteriores, coherentes con literatura clínica EEG-AD (atenuación α occipital, atrofia temporal medial).




Figura 2: Importancia por canal del SVM vainilla STFT (mejor configuración, AUC = 0,856).

4.8. Consistencia de patches entre folds (Jaccard)

Jaccard entre máscaras de patches de pares aleatorios de folds (200 pares por configuración):

Configuración	Jaccard medio $\pm$ SD
STFT Grad-CAM	0,050–0,063
STFT vainilla	0,036–0,051
CWT Grad-CAM	0,042–0,045
CWT vainilla	0,026–0,030

Los patches descubiertos son extremadamente inestables entre folds (Jaccard $\approx$ 0,03–0,06). Esto matiza la narrativa de “biomarcadores reproducibles”: cada fold descubre regiones distintas, aunque las métricas globales sean buenas.

4.9. Figura maestra




Figura 3: Resumen visual de AUC por configuración, agregando las 6 combinaciones (CNN/SVM vainilla/SVM Grad-CAM $\times$ STFT/CWT) con error bars entre seeds. Mejor configuración: SVM vainilla STFT (AUC = $0,856 \pm 0,022$).

5. Discusión

5.1. ¿CWT supera a STFT?

Respuesta: a igualdad de eje de modulación, STFT y CWT-Morlet son estadísticamente indistinguibles. Ni la hipótesis original (CWT > STFT) ni la inversa obtienen soporte. Lo importante es *cómo* se llega a esa conclusión, porque una comparación ingenua (STFT vs CWT nativa) engaña.

El eje de modulación era un confound, y controlarlo lo demuestra. STFT (noverlap=64 a fs=200) tiene Nyquist de modulación ≈ 1.56 Hz; la CWT nativa lo preserva a 100 Hz. La condición **CWT-fair** iguala ese eje manteniendo idéntica la transformada de portadora, separando los dos efectos:

	AUC vainilla	vs STFT	AUC Grad-CAM	vs STFT
STFT	0,856	—	0,713	—
CWT nativa	0,778	$-0,078$ ($p = 0,061$)	0,800	$+0,087$
CWT-fair	0,828	$-0,028$ ($p = 0,318$)	0,769	$+0,056$ ($p = 0,587$)

El patrón es consistente en dirección (aunque de magnitud distinta): en vainilla la CWT nativa parecía *peor* que STFT y en Grad-CAM parecía *mejor*; en **ambos casos**, igualar el eje **mueve la CWT hacia la STFT** (reduce $|\Delta \text{AUC}|$ de $0.078 \rightarrow 0.028$, $\sim 64\%$, y de $0.087 \rightarrow 0.056$, $\sim 36\%$). Las diferencias aparentes eran **en gran parte** el artefacto de DSP, no la transformada (con Grad-CAM el eje explica solo $\sim$ un tercio, y el efecto por seed es de signo mixto). La comparación justa (STFT vs CWT-fair) es no significativa en ambos métodos de saliency, y también la CWT-nativa vs CWT-fair ($p = 0,283, 0,527$).

Matrices que persisten (acotan la generalización):

- **CWT-fair iguala “hacia abajo”:** descarta las modulaciones rápidas ($> 1,56$ Hz) de la CWT nativa. Es la elección conservadora y fisiológicamente razonable (AM diagnóstica lenta en EA;

Fraga 2013). La alternativa (STFT con hop fino) se deja como trabajo futuro (§5.5).

- **Mayor varianza de la CWT** entre seeds (AUC $\pm 0,031$ – $0,045$ fair vs $\pm 0,022$ STFT).
- **CWT con $\text{cmor}1.5$ – 1.0 , 32 escalas log**, sin tuning específico; hiperparámetros del CNN optimizados por Lopes para input STFT.

Lectura defendible: *bajo un eje de modulación equiparable, la elección STFT vs CWT-Morlet no cambia el poder discriminativo de este pipeline.* Es más fuerte y más honesto que el resultado ingenuo, porque atribuye correctamente las diferencias a su causa (DSP), no a la transformada.




Figura 4: Espectrogramas de modulación promedio (AD vs HC) bajo STFT y CWT. La presentación 45×45 oculta el desajuste en el rango del eje de modulación (Nyquist 1,56 Hz vs 100 Hz).

5.2. El método de saliency cambia el ranking aparente — pero también vía el confound

Hallazgo metodológico: con la CWT **nativa**, el ranking se invierte según el método de saliency (Grad-CAM: CWT>STFT; vainilla: STFT>CWT). Pero esta sensibilidad **se atenúa con CWT-fair**: al quitar el confound del eje, las dos representaciones convergen bajo *ambos* métodos de saliency (§4.1–4.3). Parte de la “dependencia del método de saliency” era, otra vez, el eje de modulación interactuando con cómo cada método pondera las regiones. Los saliency maps de STFT y CWT nativa están **débilmente correlacionados** (Pearson $r \approx -0,09$ vainilla, $-0,24$ Grad-CAM, promedio de 3 seeds) — descubren regiones distintas, pero eso ya no se traduce en diferencia de desempeño una vez igualado el eje.




Figura 5: Comparación de saliency maps medios entre STFT y CWT bajo el método vainilla. Las distribuciones son cualitativamente distintas, coherente con Pearson $r \approx -0,09$.




Figura 6: Comparación cuantitativa SVM con saliency vainilla: STFT vs CWT por configuración.

5.3. Replicación del paper

Sobre ds004504, el SVM vainilla con STFT alcanza $\text{Acc} = 0,764 \pm 0,009$, $\text{AUC} = 0,856 \pm 0,022$, en el mismo orden de magnitud que el $0,71 \pm 0,02$ del paper en T2. La comparación numérica es **orientativa, no estricta**: datasets, poblaciones y detalles de anti-leakage difieren.




Figura 7: Curva ROC del SVM con saliency vainilla, agregada sobre todos los sujetos (LOSO).

5.4. Ensemble multi-seed y análisis estratificado por género

Ensemble: agregando las 3 semillas con votación por mediana (SVM vainilla STFT), la accuracy sube a 0,831 y AUC a 0,900.

Análisis estratificado por género (Fisher exact test sobre clasificación correcta):

Género	n	AD/HC	Aciertos	Acc	AUC
Mujer	35	24/11	27/35	0,771	0,852
Hombre	30	12/18	27/30	0,900	0,940
Diferencia	—	—	—	+0,129	+0,088
Fisher exact F vs M	—	—	OR $\approx$ 0,375	p = 0,201	Cohen $h \approx$ 0,35

Análisis de poder estadístico: con un tamaño de efecto Cohen $h \approx 0,35$ (moderado), detectar la diferencia observada al 80 % de poder y $\alpha = 0,05$ requeriría aproximadamente $N \approx 64$ sujetos por grupo (≈ 128 sujetos totales sumando F y M), según la fórmula con transformación arco-seno: $n_{\text{grupo}} = ((z_{1-\alpha/2} + z_{1-\beta})/h)^2 \approx 64$. El tamaño actual (35F + 30M) tiene poder $\sim 25\text{--}30\%$ para esa diferencia.

Lectura prudente: no se detectó diferencia significativa entre géneros, pero el poder estadístico es limitado — la diferencia absoluta de 12.9 puntos en accuracy es relevante en magnitud, y no podemos descartar un sesgo real del modelo. **Ausencia de evidencia no es evidencia de ausencia.**

5.5. Limitaciones

1. **Solo 3 seeds:** el multi-seed reporta varianza pero el número de réplicas es bajo para inferencias estadísticas fuertes. Idealmente ≥ 10 seeds.

2. **Grid search de patches heurístico, no nested CV**: selección por separabilidad de saliency map, no validación con SVM en val set.
3. **BH-FDR post-hoc**: la corrección se aplicó después de ver los resultados, no como pre-registro. Ninguna comparación justa (STFT vs CWT-fair) se acerca a la significancia ($q \approx 0,68$, $m = 3$).
4. **CWT-fair “igualar hacia abajo” el eje de modulación**: decima la envolvente a 3.125 Hz, descartando modulaciones $> 1,56$ Hz de la CWT nativa. Es la definición *conservadora* de “justo” (y fisiológicamente razonable), pero no única; la alternativa (igualar “hacia arriba” con STFT de hop fino) queda como futuro. Por eso la conclusión es “a igualdad de eje de modulación *lento*”.
5. **Resize bilinear**: tras igualar el eje (CWT-fair), STFT y CWT-fair parten de ~ 13 bins reales interpolados a 45, así que el resize ya no introduce asimetría entre ellas; la CWT nativa sí quedaba subsampleada.
6. **CWT subexplorada**: solo $\text{cmor}1.5-1.0$ con 32 escalas log; sin cone-of-influence; sin tuning específico.
7. **Resolución STFT real $\neq$ nominal**: $\Delta f = 1,5625$ Hz, no 1 Hz exacto.
8. **Inferencia entre seeds con solo 3 réplicas**: DeLong por seed + combinación (Stouffer/-Fisher) es correcto pero de potencia limitada; un modelo de efectos mixtos con ≥ 10 seeds sería más robusto.
9. **CNN sub-entrenada**: dropout 0.85 muy agresivo.
10. **Sin validación externa**: solo ds004504.
11. **Tareas binarias solamente**: el paper original tiene 5 tareas (T1–T5); este TFM replica solo T2.
12. **Poder estadístico modesto** para sub-análisis (género $N = 65$, potencia $\sim 25-30\%$ para $h \approx 0,35$).
13. **Saliency unstable fold-to-fold** (Jaccard $\approx 0,05$).
14. **Atribución de bandas canónicas restringida a STFT**: eje portador CWT (geospace) requiere mapeo distinto.
15. **N efectivo por autocorrelación de epochs**: el overlap 87.5% intra-sujeto NO afecta los tests reportados porque todas las inferencias finales son a nivel de sujeto.
16. **Análisis post-hoc** (bandas, importancia por canal, correlaciones, género) no estaban pre-registrados; deben verse como exploratorios.

5.6. Aporte propio

Más allá de la replicación, este TFM aporta:

1. **Evaluación multi-seed** del pipeline (el paper original no reporta varianza por seed). Aquí se cuantifica.

2. **Comparación STFT vs CWT controlando el confound DSP del eje de modulación** — el aporte metodológico central. Se identifica que STFT y CWT nativa tienen ejes de modulación no equiparables, se introduce la condición **CWT-fair** que los iguala, y se demuestra que las diferencias aparentes (en ambas direcciones y ambos métodos de saliency) eran ese artefacto: a igualdad de eje, las transformadas son indistinguibles (DeLong + Stouffer + BH-FDR).
3. **Observación de pipeline-dependencia y su origen:** el método de saliency cambia el ranking aparente entre STFT y CWT nativa, pero la sensibilidad se atenúa al controlar el eje.
4. **Conexión exploratoria con literatura clínica:** STFT + vainilla concentra saliency en bandas $\alpha + \theta$ y canales occipito-temporales.
5. **Auditoría DSP + ML documentada** y validada por dos rondas de revisión externa + revisión adversarial multi-agente del código del fix.
6. **Reproducibilidad total:** repo público con `requirements-lock.txt`, seeds fijas, configs YAML, tests unitarios pasando.

6. Conclusiones

1. **El pipeline de Lopes et al. 2023 fue replicado funcionalmente** sobre el dataset público `ds004504`. SVM con saliency vainilla y STFT alcanza $\text{Acc} = 0,764 \pm 0,009$ (comparable con el $\text{Acc } 0,71 \pm 0,02$ de Lopes en T2; el paper no reporta AUC), con $\text{AUC} = 0,856 \pm 0,022$ (3 seeds).
2. **A igualdad de eje de modulación, STFT y CWT-Morlet son estadísticamente indistinguibles; las diferencias aparentes eran un artefacto de DSP.** STFT (Nyquist de modulación 1.56 Hz) y CWT nativa (100 Hz) no codifican el mismo eje vertical antes del resize. La condición de control **CWT-fair** muestra:
 - Con *vainilla*, la CWT pasa de $-0,078$ AUC vs STFT (nativa, $p = 0,061$) a **$-0,028$** (fair, $p = 0,318$).
 - Con *Grad-CAM*, de $+0,087$ (nativa) a **$+0,056$** (fair, $p = 0,587$).
 - En **ambas direcciones** igualar el eje mueve la CWT hacia la STFT; ninguna comparación justa sobrevive BH-FDR ($q \approx 0,68$, $m = 3$). **No encontramos evidencia de que la transformada cambie el desempeño una vez controlado el eje** (potencia limitada, 3 seeds).
3. **La sensibilidad del ranking al método de saliency también era, en parte, el confound:** con CWT nativa el ranking se invierte (Grad-CAM: CWT mejor; vainilla: STFT mejor); esa inversión se atenúa con CWT-fair. Los saliency maps STFT $\leftrightarrow$ CWT están **débilmente correlacionados (cerca de cero)** ($r \approx -0,09$ vainilla, $-0,24$ Grad-CAM) — descubren regiones distintas, pero ello no se traduce en diferencia de desempeño con el eje igualado.
4. **Observaciones exploratorias (post-hoc):** STFT + vainilla concentra saliency en bandas α (61 %) + θ (28 %) y canales occipito-temporales (O1, O2, T5, T6), coherente con biomarcadores clásicos de EA. Requiere validación en datasets independientes.
5. **Hallazgos metodológicos para la comunidad:**
 - **Comparar representaciones T-F exige igualar el eje de modulación:** diferencias de resolución temporal nativa crean un confound que puede invertir el ranking aparente. CWT-fair es un control replicable.

- El método de saliency afecta las conclusiones cuantitativas; reportar siempre el método específico.
- Patches saliency-guided inestables entre folds (Jaccard $\approx 0,05$): matizar “biomarcadores reproducibles”.
- Reportar varianza por seed y poder estadístico es esencial.

6. Recomendaciones para trabajos futuros:

- Igualar el eje “hacia arriba” (STFT con hop fino) para ver si las modulaciones rápidas ($> 1,56$ Hz) que CWT-fair descarta aportan poder discriminativo.
- CWT tuning específico (cmor1-1, n_{scales} mayor, cone-of-influence).
- Ensemble STFT + CWT (late fusion) explotando la baja correlación (posible complementariedad) de los saliency maps.
- Test externo en otro dataset EEG-AD.
- Banco de filtros con bandas no uniformes.
- Nested CV para grid search; dataset balanceado por género; ≥ 10 seeds.

7. Reproducibilidad

Repositorio: <https://github.com/spalaciobe/tps-alzheimer-modspec>

Para reproducir:

```
git clone https://github.com/spalaciobe/tps-alzheimer-modspec.git
cd tps-alzheimer-modspec
python -m venv .venv && source .venv/Scripts/activate
pip install -r requirements-lock.txt && pip install -e .
python scripts/00_download_dataset.py
bash scripts/run_remaining_v2.sh
```

Tiempos en RTX 3050 Laptop (4 GB):

- Preproceso 65 sujetos: ~ 35 min.
- Modspecs (STFT + CWT): ~ 90 min.
- LOSO CNN $\times 3$ seeds $\times 2$ métodos: ~ 14 h.
- Saliency $\times 12$ corridas: ~ 12 h.
- SVM $\times 12$ corridas: ~ 12 h.
- Post-análisis + figuras: ~ 30 min.

Total: ~ 48 h de cómputo continuo.

Stack: Python 3.13, PyTorch 2.6+cu124, MNE 1.12, scikit-learn 1.8.

Declaración de uso de IA

La estructura del pipeline, scripts de orquestación, debugging de leakage en LOSO-CV, refactor de optimización (SubjectBank, fp16-bank, GC entre folds), auditoría metodológica multi-dimensional y redacción de este informe fueron asistidos por **Claude Code** (Anthropic) [Opus 4.7, 2026]. Todo el código fue revisado, ejecutado y validado por el autor antes de cada commit.

Referencias

- [1] M. Lopes, R. Cassani, T. H. Falk. Using CNN saliency maps and EEG modulation spectra for improved and more interpretable machine learning-based Alzheimer’s disease diagnosis. *Computational Intelligence and Neuroscience*, vol. 2023, art. 3198066, 2023. DOI: [10.1155/2023/3198066](https://doi.org/10.1155/2023/3198066).
- [2] A. Miltiadous *et al.* A dataset of scalp EEG recordings of Alzheimer’s disease, frontotemporal dementia and healthy subjects from routine EEG. OpenNeuro **ds004504**, CC0 1.0, 2023.
- [3] L. R. Trambaiolli *et al.* EEG spectro-temporal modulation energy: A new feature for automated diagnosis of Alzheimer’s disease. *IEEE EMBC*, pp. 3828–3831, 2011.
- [4] F. J. Fraga *et al.* Characterizing Alzheimer’s disease severity via resting-awake EEG amplitude modulation analysis. *PLoS ONE*, vol. 8, no. 8, e72240, 2013.
- [5] R. Cassani, T. H. Falk. Alzheimer’s disease diagnosis and severity level detection based on EEG modulation spectral ‘patch’ features. *IEEE J. Biomed. Health Inform.*, vol. 24, no. 7, pp. 1982–1993, 2020.
- [6] R. R. Selvaraju *et al.* Grad-CAM: Visual explanations from deep networks via gradient-based localization. *ICCV*, 2017.
- [7] K. Simonyan, A. Vedaldi, A. Zisserman. Deep inside convolutional networks: Visualising image classification models and saliency maps. *ICLR Workshop*, 2014.
- [8] L. Pion-Tonachini, K. Kreutz-Delgado, S. Makeig. ICLabel: An automated electroencephalographic independent component classifier. *NeuroImage*, vol. 198, pp. 181–197, 2019.
- [9] A. Gramfort *et al.* MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, vol. 7, no. 267, 2013.
- [10] World Health Organization. Dementia fact sheet, 2023. <https://www.who.int/news-room/fact-sheets/detail/dementia>