

¿Importa cómo descomponemos el EEG para detectar Alzheimer?

Replicación de Lopes et al. 2023 y comparación STFT vs CWT-Morlet

Sebastián Palacio Betancur

Universidad Nacional de Colombia — Sede Medellín

Facultad de Minas

Tópicos en Procesamiento Digital de Señales

Prof. Freddy Bolaños

Junio de 2026


La pregunta

- El Alzheimer es la demencia #1 (>55 M personas). Detectarlo temprano es clave, pero MRI/PET son caros.
- El **EEG** es barato y portátil. Su **espectrograma de modulación** captura *a qué ritmo* cambia la energía en cada banda — un biomarcador prometedor.
- Todo depende del primer paso: la **descomposición tiempo-frecuencia**.


Hipótesis

La **CWT**, con mejor resolución en bajas frecuencias, debería superar a la **STFT** para el Alzheimer.

Plan: replicar el pipeline de Lopes 2023 sobre datos **públicos** (OpenNeuro ds004504) y responder si la CWT gana.



Lo que construí




Idea del método (Lopes): la CNN no clasifica — *descubre* las regiones del espectrograma que separan AD de sanos; un SVM las usa como *features*.

Mi diseño: ablation completa

$$\underbrace{\{\text{STFT}, \text{CWT}\}}_2 \times \underbrace{\{\text{Grad-CAM}, \text{vainilla}\}}_2 \times \underbrace{3 \text{ seeds}}_1$$

Anti-leakage estricto: todo se calcula **por fold**.

El titular: la replicación funciona



AUC media $\pm$ SD entre 3 seeds, 6 configuraciones.

- Mejor configuración: **SVM vainilla + STFT** (la *fiel al paper*):

$$\text{AUC} = 0,856 \pm 0,022$$

- En el rango del paper original (Acc $0,71 \pm 0,02$), sobre **datos públicos independientes**.

Y a primera vista...

STFT parecía **superar** a CWT (DeLong $p = 0,014$).

Titular tentador: "STFT gana".

Replicación funcional: exitosa. Pero antes de anunciar que STFT gana, había que hacer bien la estadística.

El giro: el rigor me obligó a frenar — dos veces

Freno 1 — La estadística. El $p = 0,014$ se calculaba sobre la *mediana* entre seeds (un ensemble que infla la señal). Haciéndolo bien — DeLong **por seed** + combinación:

Comparación (vainilla)	p correcto	BH-FDR q
SVM STFT vs CWT	0,061	0,102
SVM Grad-CAM STFT vs CWT	0,068	0,102
CNN STFT vs CWT	0,266	0,266

Ninguna comparación sobrevive ($q \geq 0,10$).


Freno 2 — El DSP. Las dos imágenes son 45×45 , pero su *eje de modulación* no mide lo mismo:

	STFT	CWT
Nyquist mod.	1,56 Hz	100 Hz
Rango real	[0, 1,56]	[0, 22,5] Hz

Conclusión honesta

La comparación STFT vs CWT **no es concluyente** — y además está **confundida por DSP**. No es una comparación justa entre transformadas.

Lo que de verdad encontré



- 1 El método de saliency cambia el **ranking**: con Grad-CAM, CWT parece ganar; con vainilla, STFT. Los mapas son **estadísticamente ortogonales** ($r \approx -0,09$) $\Rightarrow$ *posible complementariedad* (idea de ensemble a futuro).
- 2 El modelo redescubre **biología conocida**: STFT vainilla concentra $\sim 89\%$ de su atención en bandas $\alpha + \theta$ y canales **occipito-temporales** (O1, O2, T5, T6) — justo donde la clínica localiza el Alzheimer.

Saliency (vainilla): STFT y CWT miran regiones distintas.

El *qué* descubre el modelo depende del pipeline completo, no solo de la transformada. Ese fue el 6/7

- 1 **La replicación funciona** sobre datos públicos — el método de Lopes es reproducible.
- 2 **La hipótesis $CWT > STFT$ no se sostiene.**... pero la contraria tampoco: el rigor manda.
- 3 **Lecciones metodológicas** más valiosas que el resultado: reportar varianza por seed, elegir bien el estadístico, y comparar transformadas solo con ejes equivalentes.

Lo primero a futuro: unificar el eje de modulación antes de volver a comparar STFT vs CWT.

Reproducibilidad

- Repo público, 3 seeds fijas.
- Anti-leakage estricto LOSO.
- Informe + auditoría externa.

[github.com/spalaciobe/
tps-alzheimer-modspec](https://github.com/spalaciobe/tps-alzheimer-modspec)

Gracias — preguntas bienvenidas.