

¿Importa cómo descomponemos el EEG para detectar Alzheimer?

Replicación de Lopes et al. 2023 y comparación STFT vs CWT-Morlet

Sebastián Palacio Betancur

Universidad Nacional de Colombia — Sede Medellín

Facultad de Minas

Tópicos en Procesamiento Digital de Señales

Prof. Freddy Bolaños

Julio de 2026


La pregunta

- El Alzheimer es la demencia #1 (>55 M personas). Detectarlo temprano es clave, pero MRI/PET son caros.
- El **EEG** es barato y portátil. Su **espectrograma de modulación** captura *a qué ritmo* cambia la energía en cada banda — un biomarcador prometedor.
- Todo depende del primer paso: la **descomposición tiempo-frecuencia**.


Hipótesis

La **CWT**, con mejor resolución en bajas frecuencias, debería superar a la **STFT** para el Alzheimer.

Plan: replicar el pipeline de Lopes 2023 sobre datos **públicos** (OpenNeuro ds004504) y responder si la CWT gana.



Lo que construí




Idea del método (Lopes): la CNN no clasifica — *descubre* las regiones del espectrograma que separan AD de sanos; un SVM las usa como *features*.

Mi diseño: ablation con **3 representaciones T-F**

$$\underbrace{\{\text{STFT, CWT, CWT-fair}\}}_3 \times \underbrace{\{\text{Grad-CAM, vainilla}\}}_2$$

CWT-fair = control (aparece en la slide 5).
Anti-leakage estricto: todo se calcula **por fold**.

El titular: la replicación funciona



AUC media $\pm$ SD entre 3 seeds.

- Mejor configuración: **SVM vainilla + STFT** (la *fiel al paper*): AUC = $0,856 \pm 0,022$, en el rango del paper (Acc $0,71 \pm 0,02$) sobre **datos públicos**.

Y aparece una diferencia curiosa

STFT vs CWT **cambia de signo** según el método de saliency: con vainilla STFT parece mejor ($0,856$ vs $0,778$); con Grad-CAM la CWT parece mejor ($0,800$ vs $0,713$).
¿Qué está pasando realmente?

Replicación funcional: exitosa. Pero antes de concluir algo sobre STFT vs CWT, hay que mirar el primer paso con lupa.

El giro: no estaba comparando peras con peras

Las dos imágenes son 45×45 , pero su **eje de modulación** (vertical) no mide lo mismo:

	STFT	CWT nativa
Nyquist modulación	1,56 Hz	100 Hz
Bins reales	~ 13	~ 180

Una comparación STFT vs CWT mezcla **dos cosas**: la transformada y la resolución del eje de modulación.

La solución: CWT-fair

Una tercera condición: la **misma CWT**, pero con la envolvente decimada para que su eje de modulación **iguale al de la STFT**.

- **STFT vs CWT-fair** $\Rightarrow$ aísla la *transformada* (comparación justa).
- **CWT nativa vs CWT-fair** $\Rightarrow$ mide el efecto del *eje* (el artefacto).

El resultado: al igualar el eje, $STFT \approx CWT$

AUC (3 seeds) — CWT-fair **se mueve hacia STFT** en las dos direcciones:

Saliency	STFT	CWT nativa	CWT-fair
Vainilla	0,856	0,778	0,828
Grad-CAM	0,713	0,800	0,769

Vainilla: brecha $-0,078 \rightarrow -0,028$. Grad-CAM:
 $+0,087 \rightarrow +0,056$.

Comparación justa (STFT vs CWT-fair)

DeLong por seed + Stouffer:

- Vainilla: $p = 0,318$
- Grad-CAM: $p = 0,587$

Ninguna sobrevive BH-FDR ($q \geq 0,58$).

A igualdad de eje de modulación, STFT y CWT-Morlet son indistinguibles.
La diferencia aparente (en ambos sentidos) era el **artefacto de DSP**, no la transformada.

- ❶ **La replicación funciona** sobre datos públicos — el método de Lopes es reproducible (AUC 0,856).
- ❷ **Comparar transformadas T-F exige igualar el eje de modulación.** Sin ese control, un artefacto de DSP puede invertir el ranking aparente. Con el control (CWT-fair), STFT y CWT empatan.
- ❸ **Aporte metodológico** > el resultado numérico: identificar el confound, diseñar el control, y demostrar que la diferencia era un artefacto.

A futuro: igualar el eje “hacia arriba” (STFT con hop fino) para ver si las modulaciones rápidas de la CWT aportan algo.

Reproducibilidad

- Repo público, 3 seeds fijas.
- Anti-leakage estricto LOSO.
- Informe + auditorías (externa y multi-agente del código).

`github.com/spalaciobe/
tps-alzheimer-modspec`

Gracias — preguntas bienvenidas.