

¿Importa cómo descomponemos el EEG para detectar Alzheimer?

Replicación de Lopes et al. 2023 y comparación STFT vs CWT-Morlet

Sebastián Palacio Betancur

Universidad Nacional de Colombia — Sede Medellín

Facultad de Minas

Tópicos en Procesamiento Digital de Señales

Prof. Freddy Bolaños


Julio de 2026

La pregunta

- El Alzheimer es la demencia #1; detectarlo temprano importa, pero MRI/PET son caros.
- El **EEG** es barato y portátil; su **espectro de modulación** captura *a qué ritmo* cambia la energía de cada banda.
- Todo depende del primer paso: la **descomposición tiempo-frecuencia**.

Hipótesis


La **CWT**, con mejor resolución en bajas frecuencias, debería superar a la **STFT** para el Alzheimer.



El artículo que replico — Lopes et al. (2023)

Detectan Alzheimer desde EEG con una idea elegante: una **CNN** *descubre* — vía saliencia — **qué regiones** del espectro separan pacientes de sanos, y un **SVM** clasifica con ellas ($\text{Acc} \approx 0,71$). **Mi plan**: replicarlo sobre datos **públicos** (ds004504) y comparar **STFT vs CWT**.

Lo que construí



Idea del método (Lopes): la CNN no clasifica — *descubre* las regiones del espectrograma que separan AD de sanos; un SVM las usa como *features*.

Mi diseño: ablation con **3 representaciones T-F**

$$\underbrace{\{\text{STFT, CWT, CWT-fair}\}}_3 \times \underbrace{\{\text{Grad-CAM, vainilla}\}}_2$$

CWT-fair = control (aparece en la slide 5).
Anti-leakage estricto: todo se calcula **por fold**.

Zoom DSP (1/3) — Limpieza: FIR 0.5–45 Hz + ICA

Qué hago

- **FIR pasa-banda 0.5–45 Hz** (fase lineal).
- **ICA + ICLabel** (+ wICA en residuos):
separa y descarta componentes *no* cerebrales (ojo, músculo, línea, ECG).

Por qué (DSP)

- **0.5 Hz** (corte alto): quita deriva/DC y sudor, por debajo del EEG útil — conserva delta.
- **45 Hz** (corte bajo): elimina línea (50/60 Hz) y EMG.
- **FIR, no IIR**: *fase lineal* $\Rightarrow$ no distorsiona el *tiempo* de la envolvente — y esa envolvente es justo lo que mide el espectro de modulación.
- **ICLabel automático**: objetivo y reproducible en 65 sujetos.

Si no

Un parpadeo o el EMG son **transitorios de alta potencia**: sin quitarlos, el espectrograma podría confundirlos con un biomarcador.

Zoom DSP (2/3) — Acondicionamiento: 200 Hz y épocas de 8 s

Qué hago

- **Remuestreo 500 $\rightarrow$ 200 Hz** (con anti-aliasing).
- **Épocas de 8 s** con solape de 1 s.

Por qué (DSP)

- Tras filtrar a 45 Hz basta Nyquist > 90 Hz: **200 Hz** (Nyquist 100) sobra y evita aliasing, con $2.5\times$ menos datos.
- **8 s** $\Rightarrow$ resolución de modulación
 $\Delta f_{\text{mod}} = 1/T = 0,125$ Hz: fina para las modulaciones **lentas** (< 2 Hz) relevantes en AD.
- Solape 1 s $\Rightarrow$ más épocas (*augmentation*).

El compromiso

Época **más corta** = peor resolución de modulación; **más larga** = se rompe la cuasi-estacionariedad del EEG. 8 s es el punto medio (y el del paper).

Zoom DSP (3/3) — Representación T-F + espectro de modulación

Qué hago

- **STFT o CWT-Morlet** $\rightarrow X(t, f)$:
 - STFT: ventana *fija* $\Rightarrow \Delta t \cdot \Delta f$ constante.
 - CWT: ventana *por escala* $\Rightarrow$ mejor Δf en bajas frecuencias.
- **Modspec**: $|X|^2 \rightarrow \mathcal{F}_t \rightarrow M(f, f_{\text{mod}})$, redimensionado a **45×45** (entrada de la CNN).


Por qué (DSP)

- STFT vs CWT es **la variable en estudio** (hipótesis: CWT mejor en bajas $\Rightarrow$ AD).
- **45×45**: tamaño de entrada fijo que exige la CNN (fiel al paper).

Sutileza

Forzar ambos a 45×45 **oculta** que el eje de modulación no mide lo mismo en STFT y CWT: ese es el *confound* que controlo con CWT-fair.


Ejemplo real: el espectro de modulación (la entrada de la CNN)



Ejes: vertical = frecuencia *portadora* (bandas $\delta, \theta, \alpha, \beta$); horizontal = frecuencia de *modulación* (a qué ritmo cambia la energía de cada banda). Cada sujeto $\rightarrow$ una imagen así (aquí promediada por grupo).

El biomarcador (panel derecho, AD—HC): en Alzheimer **sube** la actividad **lenta** (δ , rojo) y **baja** la de α (azul). Eso es lo que el modelo aprende a separar.

Ejemplo real: dónde “mira” la CNN (mapas de saliencia)




La CNN **no clasifica**: resalta las regiones del espectro que separan AD de HC (zonas claras); el **SVM** final las usa como *features*.

Pista del giro

STFT y CWT resaltan patrones **distintos** — y eso ya anticipa que no las estamos comparando en igualdad de condiciones.

La replicación funciona



AUC media $\pm$ SD entre 3 seeds.

- Mejor configuración: **SVM vainilla + STFT** (la *fiel al paper*): **Acc** = $0,764 \pm 0,009$, en el rango del paper (Acc $0,71 \pm 0,02$) sobre **datos públicos**. (AUC = $0,856 \pm 0,022$; el paper no reporta AUC.)

Y aparece una diferencia curiosa

STFT vs CWT **cambia de signo** según el método de saliency: con vainilla STFT parece mejor ($0,856$ vs $0,778$); con Grad-CAM la CWT parece mejor ($0,800$ vs $0,713$).
¿Qué está pasando realmente?

Replicación funcional: exitosa. Pero antes de concluir algo sobre STFT vs CWT, hay que mirar el primer paso con lupa.

El giro: no estaba comparando peras con peras

Las dos imágenes son 45×45 , pero su **eje de modulación** (vertical) no mide lo mismo:

	STFT	CWT nativa
Nyquist modulación	1,56 Hz	100 Hz
Bins reales	~ 13	~ 180

Una comparación STFT vs CWT mezcla **dos cosas**: la transformada y la resolución del eje de modulación.


La solución: CWT-fair

Una tercera condición: la **misma CWT**, pero con la envolvente decimada para que su eje de modulación **iguale al de la STFT**.

- **STFT vs CWT-fair** $\Rightarrow$ aísla la *transformada* (comparación justa).
- **CWT nativa vs CWT-fair** $\Rightarrow$ mide el efecto del *eje* (el artefacto).

El giro, en imágenes: al igualar el eje, el “cono” desaparece

Espectro de modulación medio: al igualar el eje, el 'cono' de la CWT desaparece y la CWT-fair se acerca a la STFT



Eje horizontal = frecuencia de **modulación**. La **STFT** concentra la energía cerca de 0; la **CWT nativa** tiene el “cono” que la extiende hasta modulaciones altas (contenido que la STFT ni siquiera mide); la **CWT-fair**, al diezmar la envolvente, **pierde el cono** y su estructura de modulación se acerca a la de STFT.

Ojo (honestidad): esto iguala el eje de *modulación* (horizontal). El de *portadora* (vertical) sigue siendo el de cada transformada — por eso convergen las *métricas*, no los mapas de saliency.

El resultado: al igualar el eje, $STFT \approx CWT$

AUC (3 seeds) — CWT-fair **se mueve hacia STFT** en las dos direcciones:

Saliency	STFT	CWT nativa	CWT-fair
Vainilla	0,856	0,778	0,828
Grad-CAM	0,713	0,800	0,769

Vainilla: brecha $-0,078 \rightarrow -0,028$ ($\sim 64\%$). Grad-CAM: $+0,087 \rightarrow +0,056$ ($\sim 36\%$).

Comparación justa (STFT vs CWT-fair)

DeLong por seed + Stouffer:

- Vainilla: $p = 0,318$
- Grad-CAM: $p = 0,587$

Ninguna sobrevive BH-FDR ($q \approx 0,68$).

A igualdad de eje de modulación, STFT y CWT-Morlet son indistinguibles.

La diferencia aparente (en ambos sentidos) era **en gran parte** un artefacto de DSP, no la transformada.

(CWT-fair iguala "hacia abajo": descarta modulaciones $> 1,56$ Hz; es 1 de 2 definiciones de comparación justa.)

- ❶ **La replicación funciona** sobre datos públicos — el método de Lopes es reproducible (AUC 0,856).
- ❷ **Comparar transformadas T-F exige igualar el eje de modulación.** Sin ese control, un artefacto de DSP puede invertir el ranking aparente. Con el control (CWT-fair), STFT y CWT empatan.
- ❸ **Aporte metodológico** > el resultado numérico: identificar el confound, diseñar el control, y demostrar que la diferencia era un artefacto.

A futuro: igualar el eje “hacia arriba” (STFT con hop fino) para ver si las modulaciones rápidas de la CWT aportan algo.

Reproducibilidad

- Repo público, 3 seeds fijas.
- Anti-leakage estricto LOSO.
- Informe técnico detallado y versionado.

`github.com/spalaciobe/
tps-alzheimer-modspec`

Gracias — preguntas bienvenidas.